

RKNN3 SDK Release Note

文件标识: RK-JC-YF-429

发布版本: V1.0.4

日期: 2026-05-15

文件密级: ☐绝密 ☐秘密 ☐内部资料 ☒公开

免责声明

本文档按“现状”提供, 瑞芯微电子股份有限公司(“本公司”, 下同)不对本文档的任何陈述、信息和内容的准确性、可靠性、完整性、适销性、特定目的性和非侵权性提供任何明示或暗示的声明或保证。本文档仅作为使用指导的参考。

由于产品版本升级或其他原因, 本文档将可能在未经任何通知的情况下, 不定期进行更新或修改。

商标声明

“Rockchip”、“瑞芯微”、“瑞芯”均为本公司的注册商标, 归本公司所有。

本文档可能提及的其他所有注册商标或商标, 由其各自拥有者所有。

版权所有 © 2025 瑞芯微电子股份有限公司

超越合理使用范畴, 非经本公司书面许可, 任何单位和个人不得擅自摘抄、复制本文档内容的部分或全部, 并不得以任何形式传播。

瑞芯微电子股份有限公司

Rockchip Electronics Co., Ltd.

地址: 福建省福州市铜盘路软件园A区18号

网址: www.rock-chips.com

客户服务电话: +86-4007-700-590

客户服务传真: +86-591-83951833

客户服务邮箱: fae@rock-chips.com

读者对象

本文档(本指南)主要适用于以下工程师:

技术支持工程师

软件开发工程师

修订记录

版本	修改人	修改日期	修改说明	核定人
V0.2.0	HPC	2025-08-16	初始版本	熊伟
V0.3.0b0	HPC	2025-09-12	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V0.4.0b0	HPC	2025-11-03	1. 更新支持的模型列表 2. 更新概述、精度、性能数据	熊伟
V1.0.0	HPC	2026-01-23	1. 更新支持的模型列表 2. 更新精度、性能数据	熊伟
V1.0.4	HPC	2026-05-15	1. 更新支持的模型列表 2. 更新精度、性能数据 3. 更新支持的硬件平台	熊伟

目录

RKNN3 SDK Release Note

1 概述

- 1.1 支持的硬件平台
- 1.2 支持的系统

2 主要特性

3 支持的模型

4 模型性能

5 模型精度

6 服务器配置推荐

7 参考

- 7.1 性能测试方法
 - 7.2 精度测试方法
-

1 概述

RKNN3 SDK提供了AI模型部署到RK1820/RK1828和RK3572所需要的软件栈，包括PC端开发套件（RKNN3 Toolkit）、板端运行API（RKNN3 Runtime）以及模型转换部署示例（RKNN3 Model Zoo）等。本次发布的SDK支持协处理器模式（RK1820/1828）和非协处理器模式（RK3572），两种模式的主要区别如下：

[协处理器模式（RK182X）]

- **主控SoC**：作为系统核心，负责任务调度、资源分配和整体控制
- **RK1820/1828协处理器**：作为AI计算加速单元，专注于高性能神经网络推理任务
- **PCIe/USB高速接口**：实现主控与协处理器之间的低延迟、高带宽数据交互

[非协处理器模式（RK3572）]

- **RK3572 SoC**：集成高性能NPU的SoC平台，支持直接运行AI推理任务
- **统一内存架构**：NPU与CPU/GPU共享内存空间

1.1 支持的硬件平台

- RK1820/RK1828 协处理器
- RK3572

1.2 支持的系统

- Android/Linux/Windows

2 主要特性

- 新增 RK3572 平台支持 (Beta)
- 新增 Windows 平台支持
- 新增以太网通信类型支持
- 新增设备休眠/唤醒支持
- 新增服务端自动选择通信方式
- 新增流式权重加载支持
- 新增模型加密支持
- 新增 LoRA 支持
- 新增 session 暂停/恢复功能
- 新增 session input callback 功能
- 新增多 session 并行运行支持
- 新增 KVCache 导入/导出接口
- 新增组件版本兼容性校验

3 支持的模型

目前支持的模型列表如下：

模型名称	模型来源
Qwen2.5-0.5B	https://huggingface.co/Qwen/Qwen2.5-0.5B
Qwen2.5-3B	https://huggingface.co/Qwen/Qwen2.5-3B-Instruct
Qwen2.5-7B	https://huggingface.co/Qwen/Qwen2.5-7B-Instruct
Qwen3-0.6B	https://huggingface.co/Qwen/Qwen3-0.6B
Qwen3-1.7B	https://huggingface.co/Qwen/Qwen3-1.7B
Qwen3-4B	https://huggingface.co/Qwen/Qwen3-4B
Qwen3-8B	https://huggingface.co/Qwen/Qwen3-8B
HY-MT1.5-1.8B	https://huggingface.co/tencent/HY-MT1.5-1.8B
Youtu-LLM-2B	https://huggingface.co/tencent/Youtu-LLM-2B
GLM-Edge-1.5B-Chat	https://modelscope.cn/models/ZhipuAI/glm-edge-1.5b-chat
Qwen2.5-VL-3B	https://huggingface.co/Qwen/Qwen2.5-VL-3B-Instruct
Qwen2.5-VL-7B	https://huggingface.co/Qwen/Qwen2.5-VL-7B-Instruct
Qwen2.5-Omni-3B (Thinker)	https://huggingface.co/Qwen/Qwen2.5-Omni-3B
Qwen3-VL-2B	https://huggingface.co/Qwen/Qwen3-VL-2B-Instruct
Qwen3-VL-4B	https://huggingface.co/Qwen/Qwen3-VL-4B-Instruct
FastVLM	https://github.com/apple/ml-fastvlm
InternVL3-2B	https://huggingface.co/OpenGVLab/InternVL3-2B
InternVL3_5-4B	https://huggingface.co/OpenGVLab/InternVL3_5-4B-Instruct
MiMo-VL-7B-RL	https://huggingface.co/XiaomiMiMo/MiMo-VL-7B-RL
Gemma-4-E2B	https://huggingface.co/google/gemma-4-E2B-it
Gemma-4-E4B	https://huggingface.co/google/gemma-4-E4B-it
SmolVLM-500M-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM-500M-Instruct
SmolVLM2-500M-Video-Instruct	https://huggingface.co/HuggingFaceTB/SmolVLM2-500M-Video-Instruct
UI-TARS-2B-SFT	https://huggingface.co/ByteDance-Seed/UI-TARS-2B-SFT
PaddleOCR VL	https://huggingface.co/PaddlePaddle/PaddleOCR-VL

模型名称	模型来源
Qwen3-Reranker-0.6B	https://huggingface.co/Qwen/Qwen3-Reranker-0.6B
Qwen3-Reranker-4B	https://huggingface.co/Qwen/Qwen3-Reranker-4B
Qwen3-Embedding-0.6B	https://huggingface.co/Qwen/Qwen3-Embedding-0.6B
Qwen3-Embedding-4B	https://huggingface.co/Qwen/Qwen3-Embedding-4B
gme-Qwen2-VL-2B-Instruct	https://huggingface.co/Alibaba-NLP/gme-Qwen2-VL-2B-Instruct
Qwen3-ASR-0.6B	https://huggingface.co/Qwen/Qwen3-ASR-0.6B
Qwen3-TTS-12Hz-1.7B	https://huggingface.co/Qwen/Qwen3-TTS-12Hz-1.7B-Base
VITS	https://github.com/jaywalnut310/vits
Whisper	https://huggingface.co/openai/whisper-large-v3
SenseVoiceSmall	https://modelscope.cn/models/iic/SenseVoiceSmall
Zipformer	https://huggingface.co/pfluo/k2fsa-zipformer-chinese-english-mixed
SigLIP	https://huggingface.co/google/siglip-so400m-patch14-384
Siglip2-so400m	https://huggingface.co/google/siglip2-so400m-patch14-384
MetaCLIP2	https://huggingface.co/facebook/metaclip-2-worldwide-m16-384
Dinov3	https://huggingface.co/facebook/dinov3-vits16-pretrain-lvd1689m
Depth-Anything-V2-small	https://huggingface.co/depth-anything/Depth-Anything-V2-Small
GR00T-N1.6-3B	https://huggingface.co/nvidia/GR00T-N1.6-3B
MobilenetV1	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/mobilenet_v1/mobilenet_v1_1.0_224.tflite
MobilenetV2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/mobilenet/mobilenetv2-12.onnx
Resnet50V2	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/resnet/resnet50-v2-7.onnx
YOLOv5s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov5/yolov5s_rknn3.onnx
YOLOv6s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov6/yolov6s_rknn3.onnx
YOLOv8s	https://ftrg.zbox.filez.com/v2/delivery/data/95f00b0fc900458ba134f8b180b3f7a1/examples/yolov8/yolov8s_rknn3.onnx

用户可以从如下网盘获取预先转好的rknn模型。RKNN3_SDK (<https://console.box.lenovo.com/l/H1fig1>, 提取码: rknn)。具体路径如下: RKNN3_SDK/rknn3_models/v1.0.4。

4 模型性能

- LLM模型性能

模型名称	加速芯片	Input Tokens	New Tokens	TTFT(ms)	TPOT(ms)	Decode TPS
Qwen2.5-0.5B	RK182X	128	128	22.74	4.48	223.40
Qwen2.5-1.5B	RK182X	128	128	49.14	6.69	149.39
Qwen2.5-3B	RK182X	128	128	85.54	9.69	103.24
Qwen2.5-7B	RK1828	128	128	162.25	14.19	70.47
Qwen3-0.6B	RK182X	128	128	28.61	5.49	182.26
Qwen3-1.7B	RK1828	128	128	54.34	7.17	139.39
Qwen3-4B	RK1828	128	128	109.78	11.30	88.47
Qwen3-8B	RK1828	128	128	182.20	16.30	61.34

- VLM模型性能

模型	加速芯片	Vision 分辨率	Vision(ms)	LLM TTFT (ms)	LLM Decode TPS
FastVLM_1.5B_stage3	RK182X	512 * 512	168.85	49.83	151.01
InternVL3-2B	RK182X	448 * 448	184.19	49.85	147.62
InternVL3_5-4B	RK1828	448 * 448	176.99	110.06	87.95
Qwen2.5-VL-3B	RK182X	392 * 392	231.4	97.85	51.48
Qwen2.5-VL-3B	RK1828	392 * 392	212.28	87.6	104.05
Qwen2.5-VL-7B	RK1828	392 * 392	215.63	163.5	69.95
Qwen3-VL-2B	RK182X	384 * 384	114.38	56.55	142.00
Qwen3-VL-4B	RK1828	384 * 384	117.6	111.45	87.8
MiMo-VL-7B-RL	RK1828	392 * 392	216.56	173.59	64.97
MiniCPM_V_4	RK1828	448 * 448	236.67	97.81	106.56

• 全模态模型

模型	加速芯片	Vision 分辨率	Vision(ms)	Audio(ms)	LLM TTFT (ms)	LLM Decode TPS
Qwen2.5-Omni-3B (Thinker)	RK1828	392 * 392	220.01	93.60	86.96	104.01
Gemma-4-E2B	RK182X	384 * 384	62.20	103.98	99.41	70.19
Gemma-4-E4B	RK1828	384 * 384	77.72	119.82	169.93	51.02

• CNN模型性能

模型名称	加速芯片	分辨率	单核性能（帧率）	多batch多核性能（帧率）
MobilenetV1	RK182X	224 * 224	388.41	1501.34
MobilenetV2	RK182X	224 * 224	279.67	1290.93
Resnet50V2	RK182X	224 * 224	112.58	843.24
YOLOv5s	RK182X	640 * 640	34.54	214.49
YOLOv6s	RK182X	640 * 640	30.73	203.46
YOLOv8s	RK182X	640 * 640	33.01	212.32

注：

- 1. RK182X 表示加速芯片可为 RK1820 或 RK1828。
- 2. Qwen2.5-VL-3B：
 - 如果使用 RK1820 加速芯片，采用两段式运行方案（LMHead在RK3588上执行）；
 - 如果使用 RK1828 加速芯片，模型推理完全在协处理器端执行。
- 3. RK1820/RK1828协处理器NPU频率均为1GHZ。
- 4. 测试基于RK3588 + RK1820/RK1828，两者之间通过PCIe连接，RK3588使用performance模式。
- 5. TTFT：模型生成第一个 token所需的时间。
- 6. TPOT：生成每个输出 token所需的平均时间。
- 7. TPS：模型每秒能生成的 token数量。
- 8. VLM 的 Vision 和 LLM 耗时为独立测试，LLM部分的 Input Tokens 和 New Tokens 均设为128。

5 模型精度

- LLM模型精度

模型名称	加速芯片	数据集	原始模型 (float32)	RKNN3 模型 (W4A16 G32)
Qwen2.5-0.5B	RK182X	gsm8k	40.71	36.09
Qwen2.5-3B	RK182X	gsm8k	79.91	80.67
Qwen3-4B	RK1828	gsm8k	90.6	89.84

- VLM模型精度

模型名称	数据集	原始模型 (float32)	RKNN3 模型 (W4A16 G32)
FastVLM_1.6B	MMbench(cn)	58.42	60.48
Qwen2.5-VL-3B	MMbench(cn)	76.8	75.43
Qwen2.5-VL-7B	MMbench(cn)	79.98	81.19
InternVL3_2B	MMbench(cn)	77.23	72.51
InternVL3_5-4B	MMbench(cn)	78.69	77.75
mimo_vl_7b	MMbench(cn)	74.7	69.85

- CNN模型精度

模型名称	数据集	原始模型 float32 (TOP1)	原始模型 float32 (TOP5)	RKNN3 模型 W8A8 (TOP1)	RKNN3 模型 W8A8 (TOP5)
MobilenetV1	imagenet	0.677	0.877	0.676	0.876
MobilenetV2	imagenet	0.694	0.888	0.680	0.882
Resnet50V2	imagenet	0.729	0.911	0.721	0.906

模型名称	数据集	原始模型 float32 AP@0.5:0.95	原始模型 float32 AP@0.5	RKNN3 模型 W8A8 AP@0.5:0.95	RKNN3 模型 W8A8 AP@0.5
Yolov5s	coco2017	0.326	0.481	0.310	0.471
Yolov6s	coco2017	0.403	0.551	0.385	0.534
Yolov8s	coco2017	0.39	0.525	0.380	0.513

6 服务器配置推荐

建议的服务器配置及转换耗时参考如下：

模型名称	服务器配置	转换耗时参考
Qwen 2.5 0.5B	32 Core CPU / 8 GB 内存 / 1TB 硬盘	约11分钟
Qwen 2.5 1.5B	32 Core CPU / 16 GB 内存 / 1TB 硬盘	约26分钟
Qwen 2.5 3B	32 Core CPU / 32 GB 内存 / 1TB 硬盘	约52分钟
Qwen 2.5 7B	32 Core CPU / 64 GB 内存 / 1TB 硬盘	约105分钟

- 如遇内存不足，可以尝试启用Swap分区扩大内存，参考：<https://wiki.debian.org/Swap>

7 参考

7.1 性能测试方法

- CNN模型性能测试方法

参考: [rknn3-runtime/examples/rknn3_model_test_demo/README_CN.md](#)

- LLM模型性能测试方法

参考: [rknn3-model-zoo/tools/rknn3_llm_test/README.md](#)

7.2 精度测试方法

- CNN模型精度测试

目前rknn3-model-zoo集成了CNN模型精度相关的测试方法及代码，用户如果需要复测模型精度，可以参考其中的说明。

1. 分类模型参考: [rknn3-model-zoo/examples/mobilenet_v2/README.md](#)

2. 检测模型参考: [rknn3-model-zoo/examples/yolov8/README.md](#)

- LLM模型精度测试

rknn3-model-zoo也集成了LLM模型精度测试的方法及代码，支持CMMLU数据集。具体测试参考 [rknn3-model-zoo/tools/rknn3_llm_test/README.md](#)